

MODELO DE MACHINE LEARNING PARA LA CLASIFICACIÓN DE CLIENTES BASADO EN DATOS RECOPIRADOS A PARTIR DE TARJETAS DE CRÉDITO

H.O. Agudelo¹

*Universidad de Antioquia, departamento de ingeniería de sistemas, Facultad de Ingeniería.
Medellín - Colombia*

Resumen— El presente proyecto se basó en la exploración de diversas técnicas de Machine Learning para la clasificación binaria de clientes en estado de deserción y fidelidad con entidades bancarias según su historial reportado en las tarjetas de crédito. Con el dataset utilizado de Kaggle, se pudo realizar un cleaning apropiado y extracción de características relevantes para alimentar el modelo y que fuera posible su correcto entrenamiento. Basado en el comportamiento de cada uno de los algoritmos utilizados, se pudo concluir que el mejor modelo fue Random Forest, ya que este logró capturar patrones clave que le permitieron discriminar mejor entre los diferentes tipos de clientes, con un accuracy del 96%. El código implementado se encuentra disponible en: <https://github.com/osvalcode/Seminario>

Palabras clave: *Machine Learning, clasificación, tarjetas de crédito, ciencia de datos*

I. INTRODUCCIÓN

La clasificación precisa de los clientes en función de la información recopilada de los movimientos en las tarjetas de crédito es de alta importancia en el sistema financiero actual. Con la creciente dependencia de las tarjetas de crédito para diversas transacciones, los bancos enfrentan el desafío de identificar y categorizar de forma efectiva a los clientes en función de su capacidad económica, hábitos de gastos y perfiles de riesgo [1].

La capacidad de clasificar con precisión a los clientes le permite a las instituciones y a las empresas ofrecer servicios personalizados, opciones de crédito ajustados a su historial y campañas de marketing dirigidas[2]. Asimismo, cumple un papel crucial en la detección y prevención de actividades fraudulentas, minimizando el riesgo crediticio y manteniendo la estabilidad general del sistema financiero.

Por lo tanto, el desarrollo de técnicas sólidas y sofisticadas para la clasificación de clientes basadas en la información de la tarjeta de crédito es esencial para que los bancos tomen decisiones informadas, mitiguen los riesgos y brinden experiencias óptimas a los clientes. Basado en esto, en el presente trabajo se propone la exploración de diversos modelos de Machine Learning para la clasificación de clientes basado en datos recopilados de tarjeta de crédito.

II. ESTADO DEL ARTE

El estudio de clientes basado en el uso de tarjetas de crédito ha sido un tema ampliamente estudiado en la industria bancaria, debido a su gran importancia en la planeación tanto de estrategias de marketing como de utilidad para la estabilidad financiera de los bancos a nivel mundial. Entre los diversos abordajes implementados, se encuentran tanto técnicas estadísticas como técnicas basadas en Machine Learning (ML). Este último, ha ido ganando gran popularidad con el paso del tiempo, el cual ha sido estudiado en diversidad de campos, como, por ejemplo, el sector financiero, brindando una herramienta útil para el análisis de los datos de los clientes y tomar decisiones basados en ello.

Para analizar las diferentes técnicas utilizadas en la literatura, se realizó una corta revisión en donde se encontraron diversas metodologías utilizadas para abordar este tipo de problemáticas y así poder compararlas con el trabajo realizado en el presente proyecto. Si bien no se encontraron artículos que implementaran el mismo conjunto de datos, se pudieron encontrar algoritmos y técnicas similares para el mismo objetivo de clasificación.

Específicamente, el trabajo realizado por [1] implementó diversas técnicas para evitar la actividad fraudulenta en el sistema de tarjetas de crédito, como algoritmos de Logistic Regression (LR), Random Forest (RF) y Bernoulli Naive Baye (NB). El rendimiento obtenido fue 96%, 98% y 95% respectivamente, exhibiendo un buen comportamiento en la clasificación de los clientes basado en ese tipo de datos.

Por otra parte, [3] desarrolló un modelo predictivo enfocado en la predicción del estado del cliente, con el objetivo de generar una alerta temprana para los bancos y así poder modificar el servicio de este u ofrecerle otros que se acoplen a sus necesidades. Para ello, utilizó métodos de selección de características y diversos modelos de ML, incluyendo Bayesian Network, C5 tree, Chi-square Automatic Interaction Detection (CHAID) tree, Classification and Regression (CR) tree, Support Vector Machine (SVM), RF, y un método basado en redes neuronales. Basado en esto, encontraron tres variables fundamentales para el aprendizaje del modelo, como el recuento total de transacciones, saldo rotativo total

en la tarjeta de crédito y el cambio en el recuento de transacciones. Para la evaluación del modelo, utilizaron un porcentaje de datos de entrenamiento, validación y prueba de 70%, 15% y 15% respectivamente, utilizando métricas de evaluación como recall, precisión, accuracy, false omission rate y F1-Score. El rendimiento de los mejores modelos se muestra a continuación en la Tabla 1.

TABLE I. RENDIMIENTO DE LOS DIFERENTES MODELOS UTILIZADOS EN [2]

Table 2. The developed models based on all variables.

Dataset	Models	Accuracy	Precision	Recall	FOR	F1 Score
Train	Bayesian Network	0.935	0.831	0.740	0.952	0.783
Train	C5-Tree	0.966	0.918	0.860	0.974	0.888
Train	CHAID	0.906	0.776	0.569	0.923	0.656
Train	CR-Tree	0.924	0.750	0.785	0.959	0.767
Train	Neural Network	0.913	0.806	0.595	0.927	0.684
Test	Bayesian Network	0.941	0.865	0.790	0.955	0.826
Test	C5-Tree	0.964	0.914	0.880	0.974	0.897
Test	CHAID	0.910	0.824	0.629	0.924	0.713
Test	CR-Tree	0.929	0.773	0.854	0.968	0.811
Test	Neural Network	0.919	0.854	0.655	0.929	0.742
Validate	Bayesian Network	0.935	0.826	0.728	0.952	0.774
Validate	C5-Tree	0.975	0.961	0.873	0.977	0.915
Validate	CHAID	0.913	0.758	0.632	0.935	0.689
Validate	CR-Tree	0.930	0.750	0.816	0.966	0.782
Validate	Neural Network	0.905	0.784	0.526	0.919	0.630

En contraste, en la revisión sistemática realizada por [4] se encontraron diversos trabajos que implementaron técnicas de ML para clasificar diferentes tipos de comportamiento basado en los datos del cliente. Entre ellos se encontró el trabajo de [5], el cual propuso un modelo híbrido para la detección de fraude basado en datos de recopilados de tarjeta de crédito utilizando Random Forest, con un accuracy del 90%. Este, se enfocaba en detectar la geolocalización de la transacción a su vez de clasificar en tiempo real el tipo de cliente (fraude vs no fraude). Por otra parte, el artículo de [6] propuso un método para detectar el riesgo de fraude basado en datos de tarjeta de crédito mediante un enfoque híbrido. En este, utilizaron una selección de características de las transacciones fraudulentas en un dataset no balanceado. Para la evaluación del modelo, el autor utilizó accuracy, recall y Area Under the Curve (AUC), obteniendo finalmente un accuracy del 95%, con una sensibilidad del 87%. El resumen de las métricas puede verse a continuación en la figura 2.

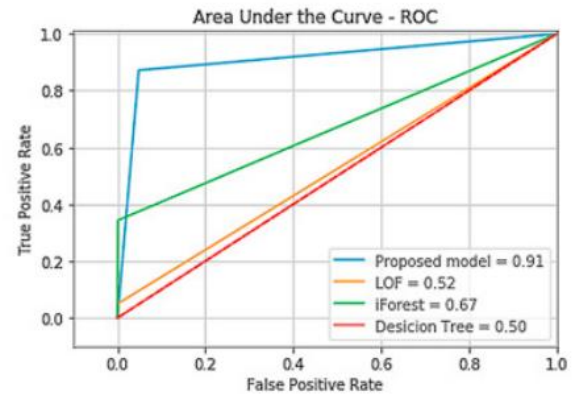



FIG I. RENDIMIENTO DE LOS DIFERENTES MODELOS TRABAJADOS POR [6]

III. EXPERIMENTOS

Para abordar el problema de detección de clientes basado en su comportamiento bancario, se utilizó la base de datos de la plataforma web de la comunidad de ciencia de datos más grande del mundo, Kaggle, llamado 'Predicting Credit Card Customer Segmentation' [7] el cual contiene amplia información de cartera de clientes de tarjeta de crédito, con el objetivo de predecir la pérdida de usuarios por parte una empresa. Este, incluye detalles tal como edad, sexo, estado civil y categoría de ingresos, así como información sobre la relación de cada cliente con el proveedor de la tarjeta de crédito, número de meses que han transcurrido desde la transacción (préstamo) y los períodos de inactividad, además de datos del comportamiento de gastos de los diferentes usuarios. A partir de este tipo de datos, se podría capturar información de interés que ayude a determinar la estabilidad de la cuenta a largo plazo y así a futuro poder brindar soluciones a clientes individuales según el comportamiento que se analice basado en los propios datos del usuario.

El número de muestras utilizadas y la cantidad de características del dataset se muestra a continuación en la figura 2.

```

RangeIndex: 10127 entries, 0 to 10126
Data columns (total 23 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   CLIENTNUM                             10127 non-null  int64
1   Attrition_Flag                         10127 non-null  object
2   Customer_Age                           10127 non-null  int64
3   Gender                                 10127 non-null  object
4   Dependent_count                        10127 non-null  int64
5   Education_Level                        10127 non-null  object
6   Marital_Status                         10127 non-null  object
7   Income_Category                        10127 non-null  object
8   Card_Category                          10127 non-null  object
9   Months_on_book                         10127 non-null  int64
10  Total_Relationship_Count                10127 non-null  int64
11  Months_Inactive_12_mon                  10127 non-null  int64
12  Contacts_Count_12_mon                   10127 non-null  int64
13  Credit_Limit                            10127 non-null  float64
14  Total_Revolving_Bal                     10127 non-null  int64
15  Avg_Open_To_Buy                         10127 non-null  float64
16  Total_Amt_Chng_Q4_Q1                   10127 non-null  float64
17  Total_Trans_Amt                         10127 non-null  int64
18  Total_Trans_Ct                           10127 non-null  int64
19  Total_Ct_Chng_Q4_Q1                     10127 non-null  float64
20  Avg_Utilization_Ratio                   10127 non-null  float64
21  NB12mon1                                10127 non-null  float64
22  NB12mon2                                10127 non-null  float64
dtypes: float64(7), int64(10), object(6)
memory usage: 1.8+ MB

```

FIG 2. NÚMERO DE MUESTRA Y CARACTERÍSTICAS DEL PROYECTO

El problema abordado se basa en la clasificación binaria de clientes, dado en este caso por su *attrition flag*, siendo 0 un cliente categorizado como desertor y 1 como cliente fiel del banco. Su respectiva distribución se muestra en el siguiente gráfico de barras. Donde se observa que hay un desbalanceo en las clases, teniendo mayor cantidad de datos de clientes fieles.

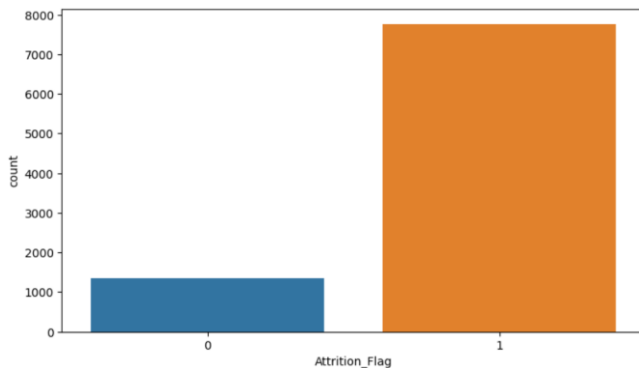


FIG 3. HISTOGRAMA DE CLASES UTILIZADAS EN EL PROYECTO

Los algoritmos utilizados para llegar al objetivo fueron SVM LR, Decision trees, RF, NV y Multi Layer Perceptron Classifier.

Para la evaluación del modelo, se implementarán métricas de rendimiento como precisión, recall, F1-score y accuracy. Las cuales se basan en las siguientes ecuaciones.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F1-score = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

FIG 3. ECUACIONES DE MÉTRICAS DE RENDIMIENTO [8]

Para evaluar el rendimiento de los modelos diseñados, se utilizó validación cruzada, la cual es método de remuestreo que utiliza diferentes subconjuntos de los datos para entrenamiento y prueba en distintas iteraciones. Asimismo, para la fase inicial se utilizó un train de 80% y un testing del 20%.

IV. RESULTADOS Y DISCUSIÓN

En el presente trabajo se realizó una aplicación de métodos de Machine Learning para la clasificación binaria de clientes basado en datos recopilados a partir de tarjetas de crédito. Este, consistió en identificar a los *attrition customer* según su comportamiento crediticio mediante el uso de diferentes algoritmos, con el fin de poder identificar su poder predictivo basado en los datos dados.

Ya que es de vital importancia entrenar el modelo con datos de alta calidad para potenciar su correcto aprendizaje, se realizó una limpieza de los datos, en la que se tuvo en cuenta la eliminación de valores faltantes, la implementación de métodos de imputación, la recodificación de columnas de la variable dependiente, la utilización de técnicas como *one hot encoding* y la detección de valores atípicos.

Una vez realizado el tratamiento de los datos, se procedió a la implementación de diferentes algoritmos para poder obtener un modelo capaz de identificar patrones en los movimientos de la tarjeta de crédito y así predecir cuándo los clientes cancelarían el uso de esta. Para tal fin, se utilizaron algoritmos como SVM LR, Decision trees, RF, NV y Multi Layer Perceptron Classifier.

Para ello, se utilizaron diversos hiperparámetros con el fin de encontrar los óptimos para el aprendizaje del modelo y que aprendiera a identificar características clave para así poder discriminar entre ambos tipos de cliente. A continuación, se muestran los resultados más relevantes obtenidos en las pruebas realizadas.

===== Accuracy de los modelos =====

```

modelSVC      : 0.9069383259911894
modelLR       : 0.9069383259911894
modelknn      : 0.8568281938325991
modelComplNB  : 0.710352422907489
modelTreeClas : 0.9394273127753304
modelRanForest: 0.9465859030837004
ModelNN       : 0.8474669603524229
    
```

FIG 4. MÉTRICAS DE RENDIMIENTO DE LOS MODELOS UTILIZADOS EN EL PROYECTO

Después de diversos entrenamientos y evaluación de métricas, se observó que el modelo que mejor se ajustó a los datos dados, fue RF, por lo que se muestra a continuación los hiperparámetros implementados para su modelado y los resultados de sus métricas obtenidas.

```

RandomForestClassifier
RandomForestClassifier(class_weight='balanced', max_depth=7,
                        max_features='auto', n_estimators=20)
    
```




FIG 4. REPORTE DE HIPERPARÁMETROS Y MÉTRICAS OBTENIDAS DEL MEJOR MODELO, RF

V. CONCLUSION

Según la exploración realizada, se encontró, según las métricas de desempeño utilizadas, que el mejor modelo para predecir la deserción de los clientes según los datos de entrada fue Random Forest, ya que pudo identificar con mayor facilidad el comportamiento de los clientes según sus movimientos crediticios. Sin embargo, el rendimiento de los otros modelos no estuvo muy alejado del mismo, concluyendo que los datos brindados al modelo fueron útiles para poder identificar patrones que ayudara a discriminar entre los diferentes tipos de clientes.

AGRADECIMIENTOS

A mi hija, por compartir no solo su conocimiento conmigo, sino su tiempo y paciencia además de su infinito amor hacia mi.

REFERENCIAS

- [1] G. A. Senthil, R. Prabha, R. M. Priya, D. Boopathi, S. Sridevi, and P. Suganthi, "Classification of Credit Card Transactions Using Machine Learning," *2022 1st International Conference on Computer, Power and Communications, ICCPC 2022 - Proceedings*, pp. 219–223, 2022, doi: 10.1109/ICCPC55978.2022.10072269.
- [2] I. Benchaji, S. Douzi, B. El Ouahidi, and J. Jaafari, "Enhanced credit card fraud detection based on attention mechanism and LSTM deep model", doi: 10.1186/s40537-021-00541-8.
- [3] D. AL-Najjar, N. Al-Rousan, and H. AL-Najjar, "Machine Learning to Develop Credit Card Customer Churn Prediction," *Journal of Theoretical and Applied Electronic Commerce Research 2022, Vol. 17, Pages 1529-1542*, vol. 17, no. 4, pp. 1529–1542, Nov. 2022, doi: 10.3390/JTAER17040077.
- [4] R. Bin Sulaiman, V. Schetinin, and P. Sant, "Human-Centric Intelligent Systems (2022) 2:55-68 Review of Machine Learning Approach on Credit Card Fraud Detection," *Human-Centric Intelligent Systems*, vol. 2, p. 3, doi: 10.1007/s44230-022-00004-0.
- [5] O. Vynokurova, D. Peleshko, O. Bondarenko, V. Ilyasov, V. Serzhantov, and M. Peleshko, "Hybrid machine learning system for solving fraud detection tasks," *Proceedings of the 2020 IEEE 3rd International Conference on Data Stream Mining and Processing, DSMP 2020*, pp. 1–5, Aug. 2020, doi: 10.1109/DSMP47368.2020.9204244.
- [6] N. Rtayli and N. Enneya, "Selection Features and Support Vector Machine for Credit Card Risk Identification," *Procedia Manuf*, vol. 46, pp. 941–948, Jan. 2020, doi: 10.1016/J.PROMFG.2020.05.012.
- [7] "Predicting Credit Card Customer Segmentation | Kaggle." <https://www.kaggle.com/datasets/thedevastator/predicting-credit-card-customer-attribution-with-m> (accessed Jun. 16, 2023).
- [8] "An Introduction to Accuracy, Precision, Recall & F1-Score in Machine Learning - Machine Learning Tutorial." <https://www.tutorialexample.com/an-introduction-to-accuracy-precision-recall-f1-score-in-machine-learning-machine-learning-tutorial/> (accessed Jun. 16, 2023).